Système d'Exploitation

Sous-système de Gestion de Processus

Université François Rabelais de Tours Faculté des Sciences et Techniques Antenne Universitaire de Blois

> Licence Sciences et Technologies Mention : Informatique 2^{ème} Année

> > Mohamed TAGHELIT taghelit@univ-tours.fr

Plan

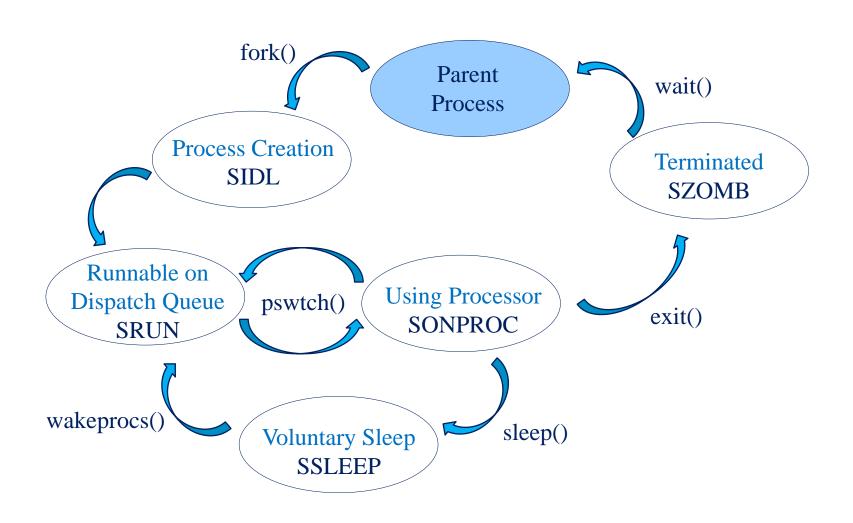
- 1. Sous-système Gestion de Processus
- 2. États d'un Processus
- 3. Ordonnancement d'Exécution
- 4. Ordonnancement Unix

Sous-système Gestion de Processus

Constitue le cœur d'un $SE \rightarrow$ coordonne tous les besoins nécessaires à la gestion des processus.

- Cycle de vie d'un processus → création, exécution et terminaison
- Ordonnancement (*Scheduling*) → les processus sont placés dans des files et leur exécution est ordonnée en fonction de leurs classe et niveau de priorité
- Commutation (*Switching*) → détermine combien de temps allouer l'UC à un processus et quand le lui retirer pour l'allouer à un autre
- Temps (*Timing*) → suivre le temps d'exécution d'un processus en surveillant le temps consommé (et donc l'horloge)
- Mémoire utilisée →coordination avec le sous-système de gestion mémoire pour les besoins d'allocation/libération mémoire (création processus, besoins propres des processus, ...)
- Coordination avec le sous-système de fichier → association processus/fichiers, localisation et transfert en mémoire pour exécution
- Gestion des exceptions → émission et réception des signaux (erreurs durant l'exécution)

États d'un processus



Ordonnancement d'Exécution

 Base des SE multiprogrammés → optimiser l'utilisation de l'Unité Centrale

Circonstances exigeant un ordonnancement

Terminaison

○ État d'exécution → État d'attente

Ordonnancement

préemptif → ○ État d'exécution → État prêt

- ó État d'attente → État prêt
- État d'exécution → Terminaison

Exécution "Elu"

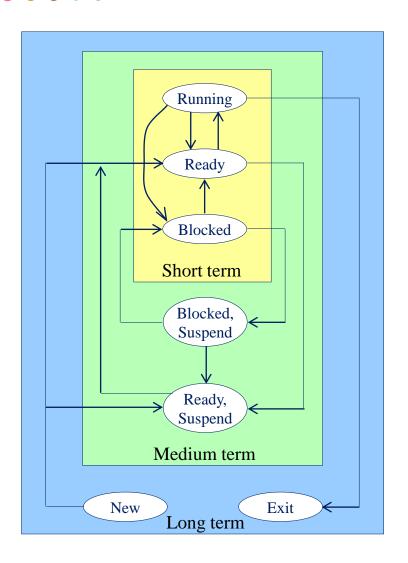
Attente

Création

 \circ Création \rightarrow État prêt

Types d'Ordonnancement

- Ordonnancement à long terme
 - Décision d'ajout de processus pour exécution
 - o Contrôle le degré de multiprogrammation
- Ordonnancement à moyen terme
 - O Décision d'ajout de processus en mémoire
- Ordonnancement à court terme
 - Décision du choix du processus devant s'exécuter



Ordonnancement Préemptif

- Traduit le fait que le processeur peut être réquisitionné
- Ordonnancement préemptif
 - Interruption de l'exécution du processus en cours
 - O Possibilité de réquisition du processeur
- Ordonnancement non préemptif
 - Changement de contexte à la fin de l'exécution du processus en cours
 - Changement de contexte volontaire du processus en cours

Critères d'Ordonnancement

- Utilisation de l'UC \rightarrow occuper l'UC au mieux [40% \leftrightarrow 90%]
- Débit ou Rendement (throughput) → nombre de processus terminés par unité de temps
- Temps de rotation ou de Service (*turnaround time*) → intervalle de temps entre la soumission d'un processus et son achèvement (¬ système interactif)
- Temps d'attente (waiting time) → somme des périodes passées en attente dans la file des processus prêts
- Temps de réponse (*response time*) → intervalle de temps entre la soumission d'une requête et la production de la première réponse

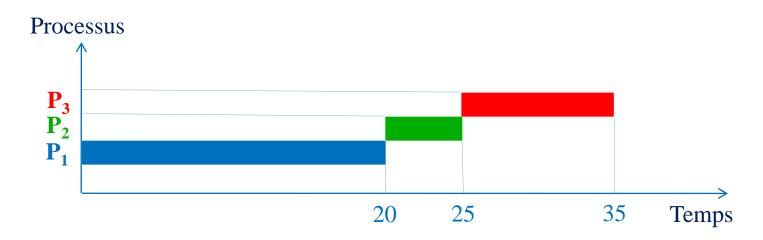
Ordonnancement FCFS

First-Come, First-Served

- Ordonnancement le plus simple
- Principe : premier arrivé, premier servi. Le premier processus qui demande l'unité centrale la reçoit en premier
- Pas de réquisition
- Implémentation → une seule file d'attente (processus prêts) FIFO
- Temps d'attente assez long
- Les processus courts peuvent être pénalisés

Exemple d'Ordonnancement FCFS

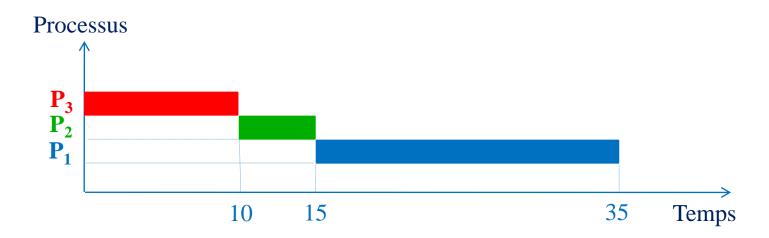
Processus	Durée	Instant Soumission	
\mathbf{P}_{1}	20	0	0
\mathbf{P}_2	5	0	Ordre d'exécution
P_3	10	0	3



• Temps d'attente moyen = 15 ms

Exemple d'Ordonnancement FCFS

Processus	Durée	Instant Soumission	
\mathbf{P}_{1}	20	0	3
\mathbf{P}_2	5	0	Ordre d'exécution
\mathbf{P}_3	10	0	



• Temps d'attente moyen = 8,33 ms

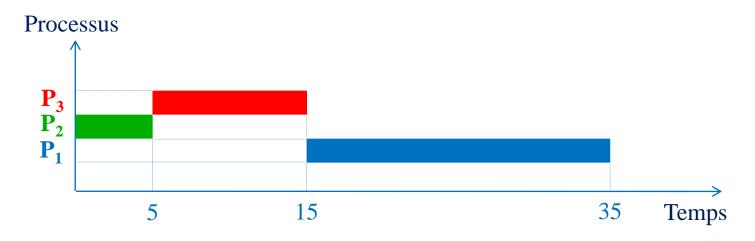
Ordonnancement SJF

Shortest-Job-First

- Principe : le processus suivant le plus court d'abord
- Si deux processus ont une même durée, alors appel à l'ordonnancement FCFS
- Implémentation → une seule file d'attente (processus prêts) non FIFO
- Pas de réquisition
- Temps d'attente moyen optimal → en exécutant un processus court avant un processus long, on diminue le temps d'attente du processus court plus que n'augmente le temps d'attente du processus long ⇒ le temps moyen décroît
- Temps d'attente moyen < Temps d'attente moyen FCFS
- Difficulté à connaître le temps d'exécution des processus

Exemple d'Ordonnancement SJF

Processus	Durée	Instant Soumission	
$\mathbf{P_1}$	20	0	3
$\mathbf{P_2}$	5	0	Ordre d'exécution
P_3	10	0	a execution



• Temps d'attente moyen = 6,66 ms

Commutation de Processus

- Une commutation est possible à chaque fois que le SE reprend le contrôle par rapport au processus en cours d'exécution.
- Événements pouvant donner le contrôle au SE :

Mechanism	Cause	Use
Interrupt	External to the execution of the current instruction	Reaction to an asynchronous external event
Trap	Associated with the execution of the current instruction	Handling of an error or an exception condition
Supervisor call	Explicit request	Call to an operating system function

• Interruptions

- Interruption Horloge
- Interruptions E/S
- o Défaut de page

Interruption Horloge

- Horloge matérielle interrompant le système à des intervalles de temps fixes
- La période de temps entre deux interruptions est appelée CPU tick, clock tick ou tick (Linux $\rightarrow jiffy$)
- Sous Unix, généralement, tick = 10 ms
- Fréquence de l'horloge (nombre de ticks/s) $\rightarrow HZ$ (param.h)
- Les fonctions du noyau mesurent toujours le temps en nombre de *ticks*
- Routine de traitement dépendant du matériel
 - Doit être courte!
 - o Très prioritaire!
- Définition d'un quantum \rightarrow 6 ou 10 *ticks*

Routine de Traitement de l'IT Horloge

- 1. Réarmer l'interruption horloge
- 2. Mise à jour des statistiques d'utilisation CPU du processus courant
- 3. Accomplir des fonctions relatives à l'ordonnancement
 - Recalculer la priorité des processus, expiration des quanta, ...
- 4. Envoyer SIGXCPU au processus courant si quota CPU dépassé
- 5. Mise à jour de l'heure du jour et de certains compteurs
- 6. Traiter les *callouts*
 - retransmission des paquets, fonctions du scheduler et du gestionnaire mémoire, scrutation des unités ne supportant pas les interruptions, ...
- 7. Réveiller processus système si nécessaire
 - swapper, pagedaemon, ...
- 8. Traiter les alarmes

Ordonnancement par Tourniquet (RR)

Round-Robin

- Conçu spécialement pour les systèmes à temps partagé
- Principe : allouer le processeur à tour de rôle aux processus pour une durée prédéfinie = quantum
- Similaire FCFS + préemption
- Implémentation → une seule file d'attente (processus prêts) FIFO
 - o Création d'un processus → insertion en queue de file
 - \circ Élection \rightarrow choisir le processus en tête de file
 - \circ Fin quantum \rightarrow réinsertion en queue de file
- Choix du quantum primordial
 - \circ Trop petit \rightarrow nombre important de commutations
 - Trop grand → temps de réponse important

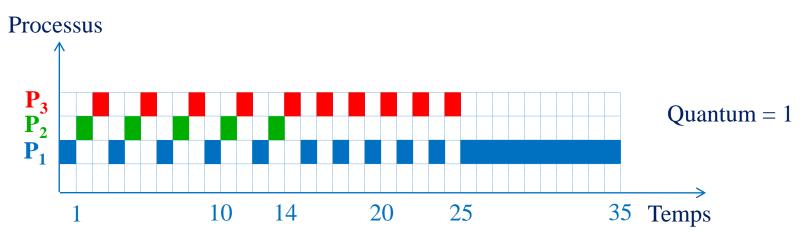
Exemple d'Ordonnancement RR

Processus	Durée	Instant Soumission	
$\mathbf{P_1}$	20	0	1
$\mathbf{P_2}$	5	0	Ordre d'exécution
P_3	10	0	3 d execution

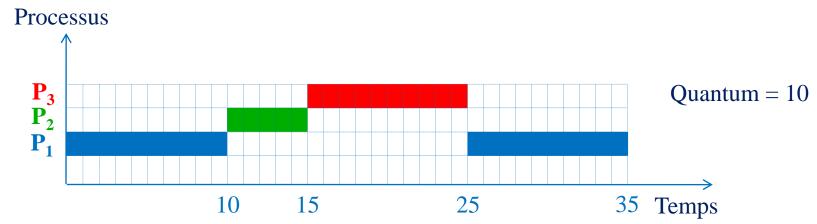


• Temps de réponse moyen = 5 ms

Exemple d'Ordonnancement RR



• Temps de réponse moyen = 1 ms



• Temps de réponse moyen = 8,33 ms

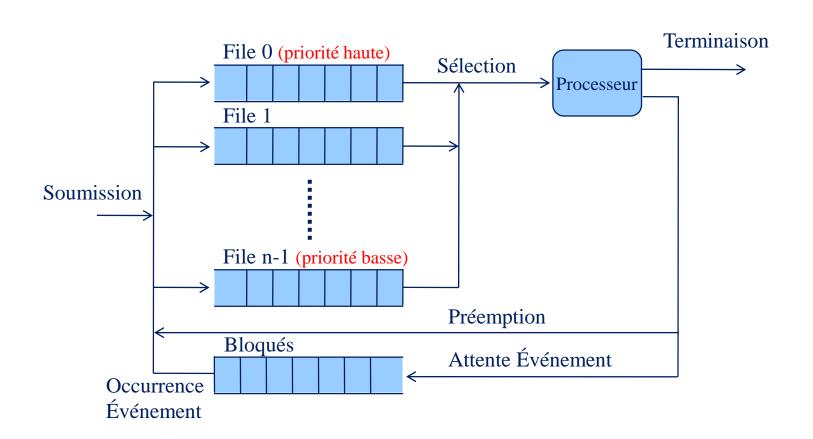
Ordonnancement à Files Multiniveaux

- Objectif : donner la possibilité de classer en différents groupes les processus et satisfaire chacun des groupes en fonction de ses besoins
 - O Par exemple, les processus en avant-plan et les processus en arrière-plan qui ont des besoins de temps de réponse différents, ...

• Principe:

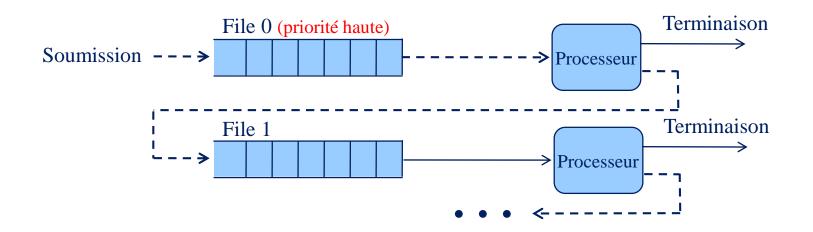
- o Partitionner la file des processus prêts en plusieurs files séparées
- Les processus sont affectés à une file (en fonction du type ou de la priorité des processus, par exemple)
 - Le processus est toujours affecté à la même file
 - Le processus change de file au cours de son exécution
- Chaque file possède son propre algorithme d'ordonnancement
- Établir un ordonnancement entre les files (généralement, ordonnancement préemptif à priorité fixée)
- Implémentation → une file par niveau

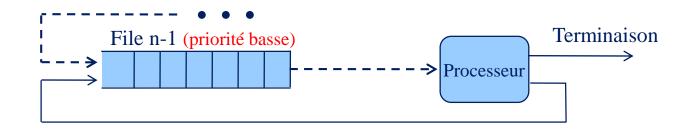
Ordonnancement avec Priorités Statiques



Risque de famine si les files + prioritaires sont toujours approvisionnées.

Ordonnancement avec Priorités Dynamiques





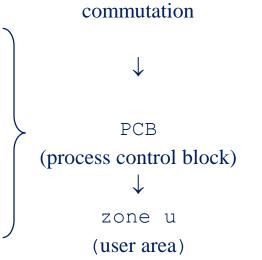
Remonter régulièrement (x quanta) d'un niveau toutes les tâches pour éviter la famine.

Ordonnancement traditionnel Unix

- Ordonnancement basé sur les priorités
- Chaque processus a une priorité qui change dans le temps
- Le *scheduler* sélectionne toujours le processus prêt de plus haute priorité
- Ordonnancement des processus de même priorité par préemption et modification dynamique de leur priorité selon leur utilisation de la CPU
- Si un processus de plus haute priorité devient prêt, préemption du processus courant même s'il n 'a pas entièrement consommé son quantum
- Le noyau Unix traditionnel est non-préemptif
 - un processus en mode noyau ne peut être forcé à céder la CPU pour un processus plus prioritaire
 - le processus courant peut volontairement libérer la CPU lorsqu'il doit bloquer sur une ressource, ou bien il est préempté lorsqu'il retourne en mode utilisateur

Contexte d'un processus

- Espace d'adressage utilisateur
 - code, données, pile user, segments de mémoire partagée, ...
- Informations de contrôle
 - zone u et structure proc
- Appartenance (credentials)
 - UID, GID
- Variables d'environnement
 - "variable = valeur"
- Contexte matériel
 - Compteur ordinal (program counter-PC),
 - Pointeur de pile (stack pointer-SP),
 - Mot d'état du processeur (processor status word-PSW):
 état du système, mode d'exécution,
 niveau de priorité d'interruption, ...
 - Registres de gestion mémoire
 - registres FPU (floating point unit)



Zone u (user)

- struct user → <sys/user.h>
- Fait partie de l'espace du processus → swappable
- mappable et visible uniquement lorsque le processus s'exécute (référence : u)
 - process control block (pcb),
 - pointeur vers la structure proc du processus,
 - UID et GID effectifs et réels,
 - arguments, valeurs de retour ou code d'erreur de l'appel système courant,
 - informations sur les signaux (gestionnaires, ...),
 - entête du programme (tailles du code, des données et de la pile ainsi que des information sur la gestion mémoire),
 - table des descripteurs de fichiers ouverts (extensible dynamiquement : SVR4),
 - pointeurs vers vnodes du répertoire courant et du terminal de contrôle,
 - statistiques d'utilisation CPU, quotas disques, limites des ressources,
 - pile système (dans certaines implémentations),

• •

Structure proc

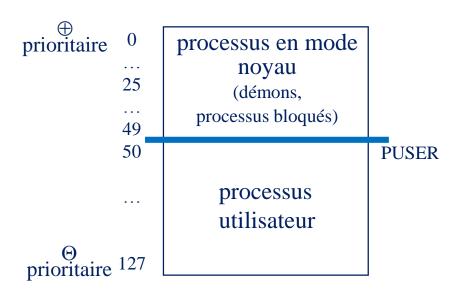
- struct proc → proc.h
- Appartient à l'espace noyau → visible par le noyau à tout instant, même quant le processus n'est pas en cours d'exécution,
 - identification: PID, GID, [SID],
 - pointeur zone u,
 - état courant du processus,
 - pointeurs (avant, arrière) vers listes de processus prêts, bloqués, ...
 - événement bloquant,
 - priorité + information d'ordonnancement,
 - masque des signaux,
 - information mémoire,

. . .

Priorités des processus

- La priorité d'un processus peut être une valeur entière comprise entre 0 et 127
- La structure proc contient les champs (relatifs à la priorité) suivants :

_	p_pri	Priorité (d'ordonnancement)
		courante
_	p_usrpri	Priorité en mode utilisateur
		(égale à p_pri en mode user)
_	p_cpu	Mesure de l'utilisation
		récente de la CPU
_	p_nice	Incrément de priorité
		contrôlable par l'utilisateur
_	p_slptime	Temps passé par le processus
		dans l'état endormi



Calcul de Priorité

- Répartir équitablement le processeur →
 - baisser la priorité des processus lors de l'accès au processeur
- A chaque tick, la routine horloge incrémente p_cpu pour le processus courant (p_cpu++)
- Régulièrement, le noyau appelle schedcpu () pour réduire la valeur de p_cpu
 - appelée 1 fois par seconde
 - Pour tous les processus prêts :

```
p_cpu = p_cpu * decay

decay = ½

decay = (2*load_average)/(2*load_average+1)

p_usrpri = PUSER + (p_cpu/4) + (2*p_nice)
SVR3
```

- Évite la famine des processus de faible priorité
- Favorise les processus qui font des E/S par rapport aux processus qui font du calcul
- Un processus qui a eu un accès récent → p_cpu élevé → p_usrpri élevé.

Les primitives internes

C'est toujours le processus de plus haute priorité qui s'exécute, à moins que le processus courant soit en mode noyau

Si tous les processus prêts sont dans des files de moindre priorité, le processus courant continue son exécution même si son quantum de temps a expiré

- Après 4 *ticks*, appel de *setpriority()* pour mettre à jour la priorité du processus courant
- 1 fois par seconde, appel de schedcpu () pour la mise à jour des priorités de tous les processus
 - retire le processus de la file, recalcule la priorité, remet le processus dans la file (éventuellement différente)
- roundrobin () appelée en fin de quantum pour élire un nouveau processus dans la même file

Exemple

Supposons:

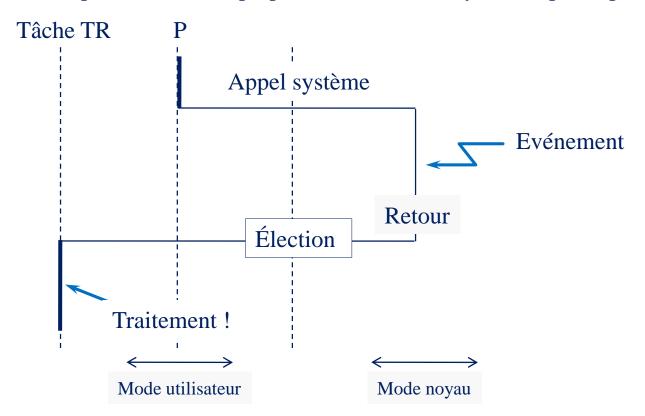
- Trois processus A, B et C
- Créés au même instant avec priorité de base = 60 (PUSER)
- Interruption horloge, 60 fois par seconde
- Aucun processus ne bloque par luimême
- Aucun autre processus n'est prêt à s'exécuter
- Calcule de priorité :
 - o $p_cpu = p_cpu * \frac{1}{2}$

	_	_					
0	p_	_usrpri	=	PUSER	+	(p_	_cpu/2)

Time	Processus A		Proce	essus B	Processus C		
	Priority	CPU Count	Priority	CPU Count	Priority	CPU Count	
0 —	60	0 1 2	60	0	60	0	
1 - 2 -	75	30	60	0 1 2	60	0	
	67	15	75	30	60	0 1 2	
3 -	63	7 8 9	67	15	75	30	
4 -	76	33	63	7 8 9	67	15	
5 —	68	16	76	33	63	7 8 9	
6 —							

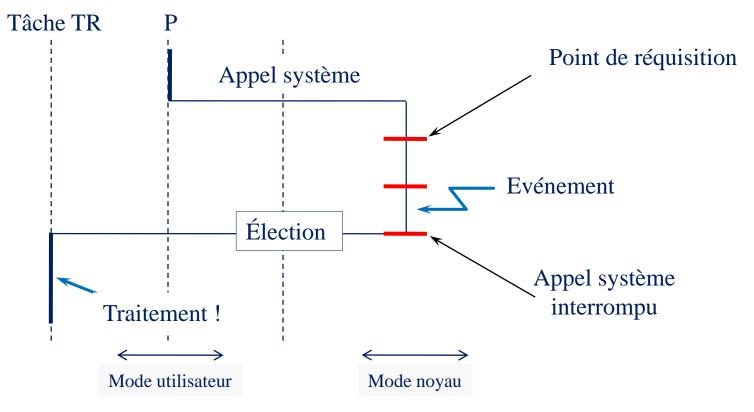
Contraintes Temps Réel

- Objectif : satisfaire des contraintes de temps
 - Processus temps réel très prioritaire en attente d'événement
- Impossible dans la plupart des Unix car noyau non-préemptif!



Points de réquisition

• Solution 1 : vérifier régulièrement si un processus plus prioritaire doit être exécuté (SVR4)

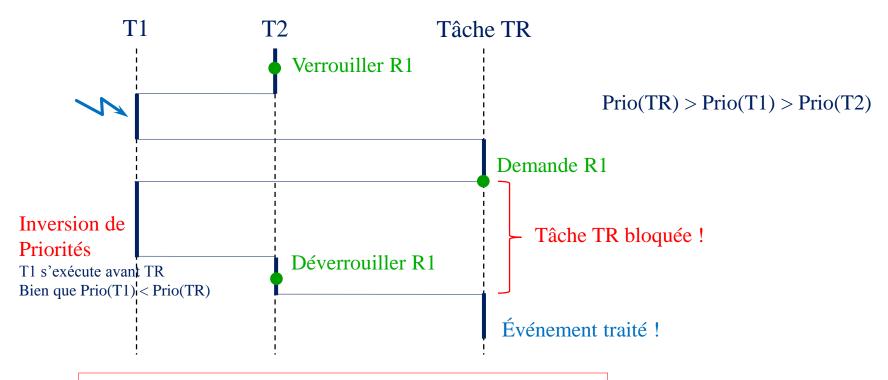


- Il est difficile de placer de nombreux points de réquisition
 - ⇒ latence de traitement importante

Noyaux Préemptifs (Solaris 2.x)

- Solution 2 : rendre le noyau préemptif

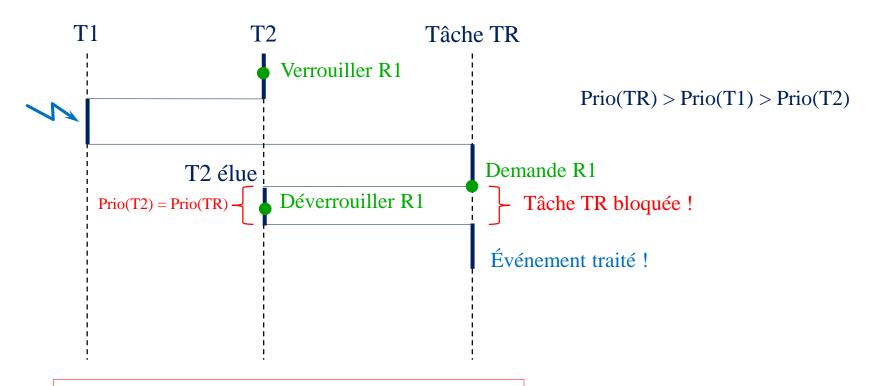
 ⇒ en mode noyau l'exécution peut être interrompue par des processus plus prioritaires
- Protéger toutes les structures de donnée du noyau par des verrous (~ sémaphores)



Tâche TR dépendant de l'exécution de la tâche T2!

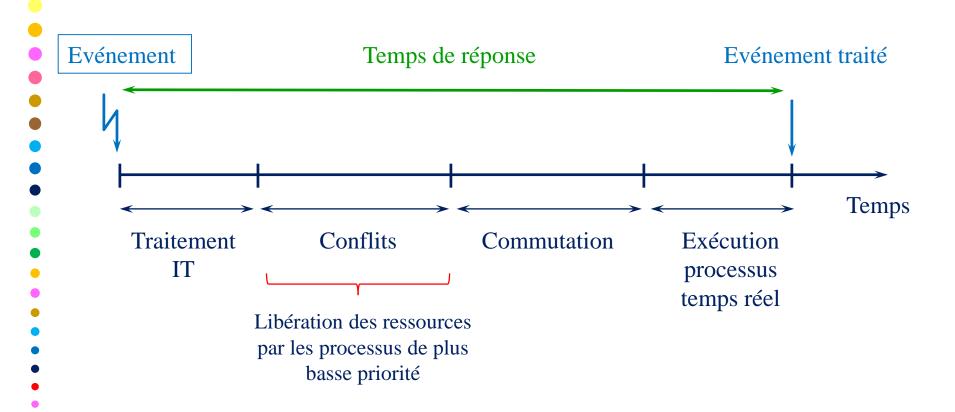
Héritage de priorité

• Solution : Donner à la tâche qui possède la ressource la priorité de la tâche temps réel



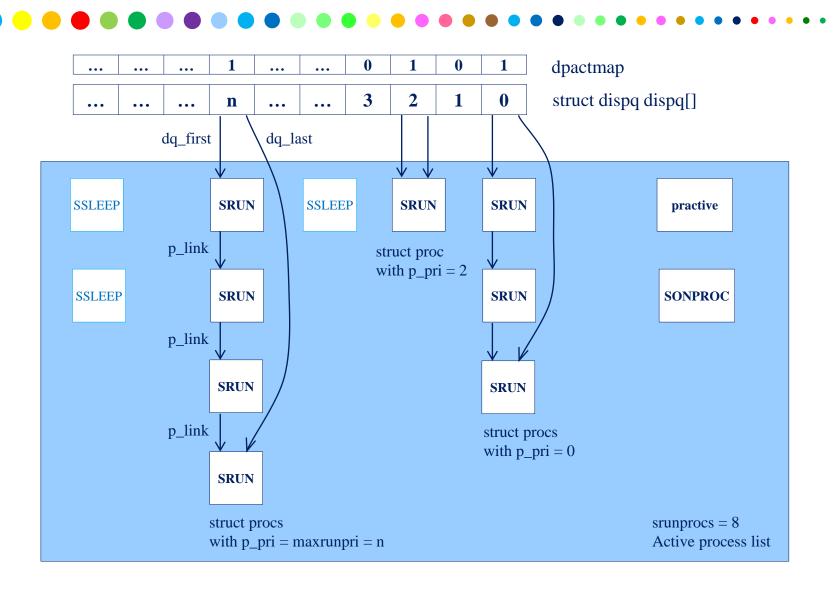
T2 hérite temporairement de la priorité de TR

Temps de réponse



Ordonnancement Unix : Implémentation (Hors Programme)

Implémentation des Files de Processus Prêts

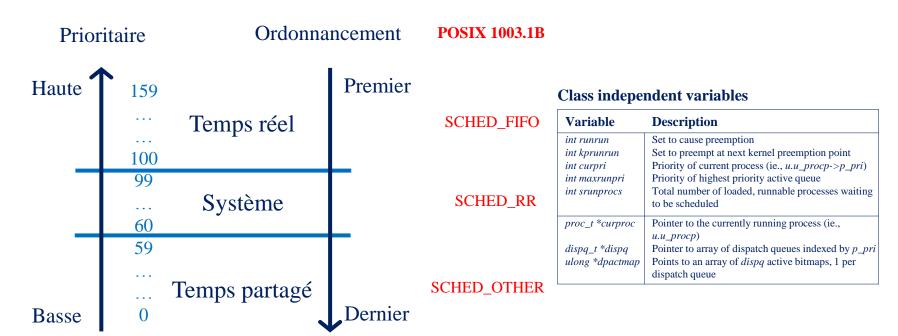


Algorithme de swtch ()

- Il existe trois situations où la commutation est indiquée
 - Le processus courant bloque sur une ressource ou se termine. Il s'agit d'une commutation de contexte volontaire.
 - la procédure de recalcule de priorité résulte en l'existence d'un autre processus de priorité plus élevée que celle du processus courant.
 - Le processus courant, ou un gestionnaire d'interruption, réveille un processus de priorité plus élevée.
- Pour la commutation non volontaire, le noyau utilise un flag (runrun)
 Sur retour en mode utilisateur, si runrun positionné → appel de swtch ()
- Algorithme de swtch ()
 - Trouver le premier bit positionné dans whichqs
 - Retirer le processus le plus prioritaire de la tête de file
 - Effectuer la commutation :
 - Sauvegarder le PCB (Process Control Bloc) du processus courant (inclus dans zone u)
 - Changer la valeur du registre de la table des pages (champs p_addr de struct proc)
 - Charger les registres du processus élu à partir de la zone u

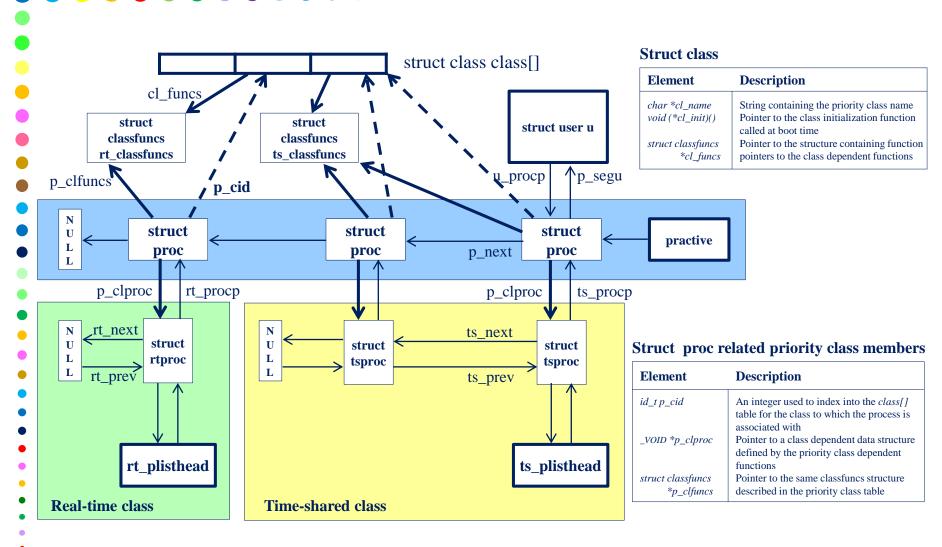
SVR4: Classes d'ordonnancement

• 3 classes de priorités sont définies



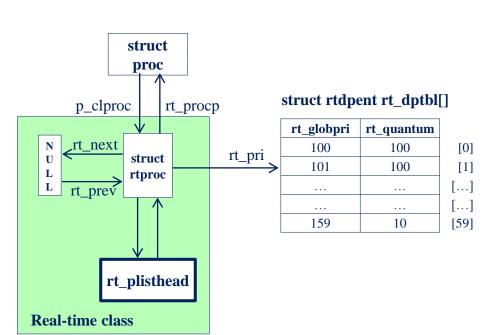
- Les processus temps réel prêts s'exécutent tant qu'ils restent prêts
- Définition des processus temps réel réservée au superviseur (appel système priocnt1 SVR5 setsched prio POSIX)

SVR4: Structures



Classe Temps Réel

• Politique d'ordonnancement à priorités fixes



Struct rtdpent

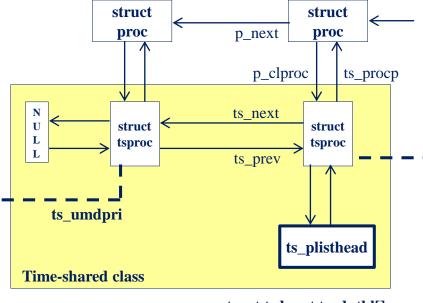
Element	Description
int rt_globpri	Default global priority (from 100 – 159)
long rt_quantum	Default time-quantum (slice) for this level specified in clock ticks

Struct rtproc

Element	Description
long rt_pquantum	Time-quantum assigned to this process
long rt_timeleft	Time remaining in time-quantum
short rt_pri	Priority level (offset into <i>rt_dptbl[]</i>)
ushort rt_flags	Flags: RTRAN – process has run since last
	swap out, RTBACKQ – process is placed on
	the back of its dispatch queue when next
	prempted
struct proc *rt_procp	Pointer to process in the active list
char *rt_pstatp	Pointer to <i>p-stat</i> in <i>rt_procp</i>
int *rt_pprip	Pointer to <i>p_pri</i> in <i>rt_procp</i>
uint *rt_pflagp	Pointer to <i>p_flag</i> in <i>rt_procp</i>
struct rtproc *rt_next	Pointer to next <i>rtproc</i> in list
struct rtproc *rt_prev	Pointer to previous <i>rtproc</i> in list
_	

Classe Temps Partagé

- Quantum variable d'un processus à l'autre
- Inversement proportionnel à la priorité!
- Définis statiquement pour chaque niveau de priorités



struct tsdpent ts_dptbl[]

	ts_globpri	ts_quantum	ts_tqexp	ts_slpret	ts_maxwait	ts_lwait	
	0	100	0	10	5	10	[0]
>	1	100	0	11	5	11	[1]
			•••				[]
			•••				[]
	59	10	49	59	5	59	[59]

Struct tsdpent

Element	Description
int ts_globpri	Default global priority (from 0 – 59)
long ts_quantum	Default time-quantum (slice) for this level specified in clock ticks
short ts_tqexp	Assigned value to <i>ts_cpupri</i> when this process's time-quantum expires
short ts_slpret	Assigned value to <i>ts_curpri</i> upon returning to usermode after a sleep
short ts_maxwait	Maximum number of consecutive seconds that the process can run in its allocated time-quantum before assigning ts_lwait to ts_cpupri
short ts_lwait	Assigned value to ts_cpupri if ts_dispwait exceeds ts_maxwait

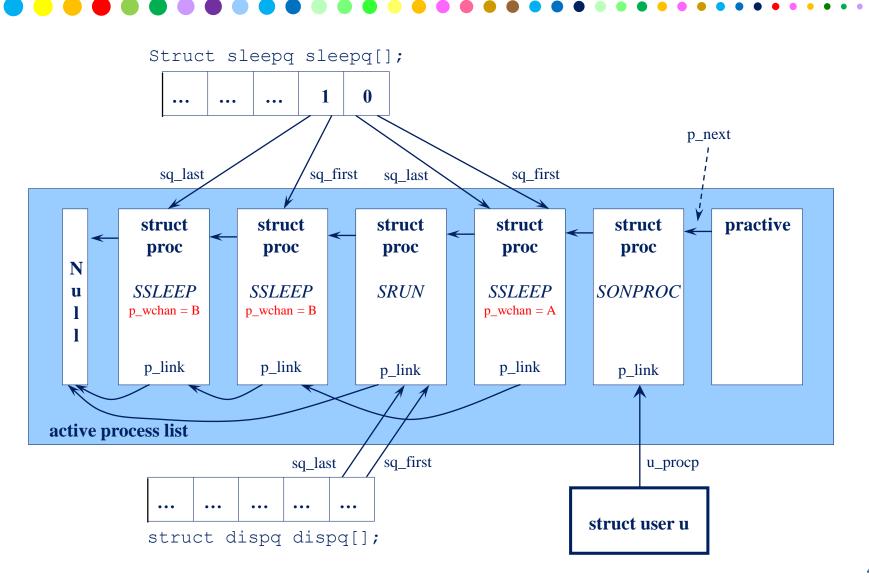
Struct tsproc

Element	Description		
long ts_timeleft	Remaining time in process's time-quantum		
short ts_cpupri	Kernel portion of priority value		
short ts_uprilim	User modifiable – priority value limit, set with priocntl		
short ts_upri	User modifiable – current user portion of priority value		
short ts_umdpri	Offsets into ts_dptbl[] to find the global priority level		
char ts_nice	Nice value (for backward compatibility)		
unsigned char ts_flag	Operational flags		
short ts_dispwait	Number of seconds since start of current time-quantum (not reset upon preemption)		
struct proc *ts_procp	Pointer to process's proc structure		
char *ts_pstatp	pointer to p_stat in proc structure		
int *ts_pprip	Pointer to p_pri in proc structure		
uint *ts_pflagp	Pointer to p_flag in proc structure		
struct tsproc *ts_next	Link to next tsproc on tsproc list		
struct tsproc *ts_prev	Link to previous tsproc on tsproc list		

Processus Endormis

- Les processus s'endorment volontairement en attente de la disponibilité d'une ressource ou de l'occurrence d'un événement
 - o Inode verrouillé, lecture (écriture) dans un pipe vide (plein), achèvement d'une E/S disque, Lecture du terminal, attente de mémoire (défaut de page)
- Les processus s'endorment sur des événements
 - o Événements qui permettent aux processus de se réveiller par un signal
 - Événements qui font que les signaux sont ignorés (processus endormis indéfiniment jusqu'à l'occurrence de l'événement)
- Les processus (temps partagé) sont endormis avec une haute priorité ≠ priorité utilisateur (p_pri ≠ p_usrpri) → Au réveil le processus a une plus grande probabilité d'être élu
- Au passage en mode utilisateur, l'ancienne priorité est restaurée (p_pri = p_usrpri)

File des processus endormis



Priorités Système

• Les priorités système sont décrites dans la table ts_kmdpris[]

```
int ts_kmdpris[] = {
      60,61,62,63,64,65,66,67,68,69,
      70,71,72,73,74,75,76,77,78,79,
      80,81,82,83,84,85,86,87,88,89,
      90,91,92,93,94,95,96,97,98,99
};
```

40 nombres contigus représentant les niveaux de priorités de la classe système.

Divisés en intervalles appelés niveaux de priorités système .

Chaque niveau de priorités système correspond à un type d'événements.

• Chaque processus devant s'endormir, doit préciser le type d'événement sur lequel il s'endort

Sleep parameter	Parameter value	Global priority value	Description
PSWP	0	99	Swapper priority
PMEM	0	99	Locked memory
PINOD	10	89	Locked inode
PRIBIO	20	79	Block I/O
PZERO	25	74	Signal level
PPIPE	26	73	Empty or full pipe
PVFS	27	72	Wait for unmount of file system
TTIPRI	28	71	Terminal input
TTOPRI	29	70	Terminal output
PWAIT	30	69	Wait for SIGCHLD
PSLEP	39	60	Pause for signal

Plus haute priorité système (type d'événement) pouvant être passée en paramètre à *sleep()*

Nouvelle priorité du processus :

Exemple de Calcul de priorité

```
Processus \rightarrow sleep(PRIBIO + 1)
Nouvelle priorité du processus
       *tsproc->ts pprip =
       ts kmdpris[ts maxkmdpri - (PRIBIO + 1)]
       == ts kmdpris[18]
       == 78 ←
       == proc->p pri
        int ts kmdpris[] = {
                60,61,62,63,64,65,66,67,68,69,
                70,71,72,73,74,75,76,77,78,79,
                80,81,82,83,84,85,86,87,88,89,
                90,91,92,93,94,95,96,97,98,99
        };
```

Bibliographie

- The magic garden explained, The internals of Unix System V Release 4
 Berny Goodheart & James Cox Prentice Hall
- Operating Systems, Internals and Design Principles,
 Willam Stallings Printice Hall
- Principes des Systèmes d'Exploitation,
 A. Silberschatz, P.B. Galvin, G. Gagne Vuibert
- Introduction aux Système Unix, Support de cours,
 Eric Gressier CNAM-CEDRIC